

# 基于图像的三维模型重建

## ——双视角SFM



主讲人 隋博士



## ✓ 三角量测(Triangulation)

- ✓ 直接线性变换法

## ✓ 3D-2D: PnP问题

- ✓ 直接线性变换法
- ✓ 非线性优化

## ✓ 捆绑调整Bundle Adjustment

## 已知相机参数和匹配点恢复三维点的坐标

第  $i$  相机投影矩阵:


$$P_i = K_i [R_i, t_i] = \begin{bmatrix} P_{i1} \\ P_{i2} \\ P_{i3} \end{bmatrix}$$

三维点点坐标:

$$X = [x, y, z, 1]^T$$

在第  $i$  个视角中投影的图像坐标为:

$$\mathbf{x}_i = [x_i, y_i, 1]^T$$



## 已知相机参数和匹配点恢复三维点的坐标

根据投影方程可以得到：

$$\mathbf{x}_i = P_i X,$$

上述等式两侧同时叉乘  $\mathbf{x}_i$ ：

$$\mathbf{x}_i \times (P_i X) = \mathbf{0}$$

即

$$\begin{aligned} x_i(P_{i3}X) - P_{i1}X &= 0 \\ y_i(P_{i3}X) - P_{i2}X &= 0 \\ x_i(P_{i2}X) - y_i(P_{i1}X) &= 0 \end{aligned}$$



$$\begin{bmatrix} x_i P_{i3} - P_{i1} \\ y_i P_{i3} - P_{i2} \end{bmatrix} X = 0$$

注意 第3个方程与前两个方程线性相关

## 已知相机参数和匹配点恢复三维点的坐标

1个观察点提供2个约束， $X$ 有3个自由度，至少2对点

$$A X = 0,$$

$$A = \begin{bmatrix} x_1 P_{13} - P_{11} \\ y_1 P_{13} - P_{12} \\ \dots \\ x_i P_{i3} - P_{i1} \\ y_i P_{i3} - P_{i2} \\ \dots \\ x_N P_{N3} - P_{N1} \\ y_N P_{N3} - P_{N2} \end{bmatrix}, N \geq 2$$

## 思考


如果存在外点（匹配点或姿态）的情况下，如何得到准确的三维点坐标？

## Coding-1:

完成task-3/class3\_test\_triangulation.cc中利用直接线性变化法求三维点坐标

# 3D-2D:PnP问题-PnP

已知三维点和对应二维点求解相机内外参数






# 3D-2D:PnP问题-直接线性变换法

## 已知三维点和对应二维点求解相机内外参数

$$s \begin{pmatrix} u \\ v \\ 1 \end{pmatrix} = K [R, t] \begin{pmatrix} X \\ Y \\ Z \\ 1 \end{pmatrix} = \begin{bmatrix} T_{11} & T_{12} & T_{13} & T_{14} \\ T_{21} & T_{22} & T_{23} & T_{24} \\ T_{31} & T_{32} & T_{33} & T_{34} \end{bmatrix} \begin{pmatrix} X \\ Y \\ Z \\ 1 \end{pmatrix} = \begin{pmatrix} r_1^T \\ r_2^T \\ r_3^T \end{pmatrix} X$$


$$u = \frac{T_{11}X + T_{12}Y + T_{13}Z + T_{14}}{T_{31}X + T_{32}Y + T_{33}Z + T_{34}} = \frac{X^T r_1}{X^T r_3}$$

$$v = \frac{T_{21}X + T_{22}Y + T_{23}Z + T_{24}}{T_{31}X + T_{32}Y + T_{33}Z + T_{34}} = \frac{X^T r_2}{X^T r_3}$$


$$X^T r_1 - X^T r_3 u = 0$$

$$X^T r_2 - X^T r_3 v = 0$$

# 3D-2D:PnP问题-直接线性变换法

已知三维点和对应二维点求解相机内外参数

$$\begin{pmatrix} X_1^T & 0 & -uX_1^T \\ 0 & X_1^T & -vX_1^T \\ \vdots & \vdots & \vdots \\ X_N^T & 0 & -uX_N^T \\ 0 & X_N^T & -vX_N^T \end{pmatrix} \begin{pmatrix} r_1 \\ r_2 \\ r_3 \end{pmatrix} = 0$$

共需要至少6对3D-2D对应点

$T=[KR, Kt]$  矩阵QR分解获取K,R,t

# 3D-2D:PnP问题-其它常用方法

**P3P法:** 需要4对不共面的点 求出2D点在当前相机坐标系中的3D点, 然后进行3D-3D的姿态求解

<https://www.cnblogs.com/mafuqiang/p/8302663.html>

[Complete Solution Classification for the Perspective-Three-Point Problem](#)

A novel parametrization of the perspective-three-point problem for a direct computation of absolute camera position and orientation

**ePnP法:** 需要( $\geq 4$ 不共面或者3对共面) 点进行求解

<https://www.cnblogs.com/jian-li/p/5689122.html>

[EPnP: Efficient Perspective-n-Point Camera Pose Estimation](#)

# 课程内容

## ✓ 针孔相机模型

- ✓ 针孔相机模型
- ✓ 径向畸变

## ✓ 2D-2D: 对极几何

- ✓ 对极约束
- ✓ 本质/单应矩阵
- ✓ 直接线性变换法

## ✓ 3D-2D: PnP问题

- ✓ 三角量测
- ✓ 直接线性变换法
- ✓ 非线性优化

## ✓ 捆绑调整 Bundle Adjustment

# 捆绑调整 Bundle Adjustment

## 问题阐述 同时对三维点位置和相机参数进行非线性优化

观测点


三维点坐标  $X_i = (X_i, Y_i, Z_i)^T$

$$g(\theta) = \frac{1}{2} \sum_i^n \sum_j^m \chi_{ij} \left\| \hat{u}_{ij} - u_{ij}(C_j, X_i) \right\|^2 = \frac{1}{2} \sum_i^n \sum_j^m \chi_{ij} e_{ij}^2, \quad \theta = (C_1, \dots, C_m, X_1, \dots, X_n)$$

投影点 相机参数  $C_j = (f_j, k_{1j}, k_{2j}, R_j, t_j)$

$\chi_{ij}=1$  表示第  $i$  个点在第  $j$  个相机中可见

$\theta \in \mathbb{R}^{9m \times 3n}$  高维空间的非线性优化



# 捆绑调整 Bundle Adjustment

## 无约束非线性最小优化问题

$$\min g(\theta) = \min \|x - f(\theta)\|^2, \theta \in \mathbb{R}^n$$

优化上述问题的最优解通常是指它的局部最优解，因此需要一个较好的初始值

# 捆绑调整 Bundle Adjustment

## 最速下降法—假设函数一阶可微

假设 $g(\boldsymbol{\theta})$ 在 $\boldsymbol{\theta}_t$ 处可微, 则它在 $\boldsymbol{\theta}_t$ 处有Taylor展开式:

$$g(\boldsymbol{\theta}) = g(\boldsymbol{\theta}_t) + (\nabla g(\boldsymbol{\theta}_t))^T \delta \boldsymbol{\theta} + o(\|\delta \boldsymbol{\theta}\|),$$


其中  $\boldsymbol{\theta} = \boldsymbol{\theta}_t + \delta \boldsymbol{\theta}$

- 当  $(\nabla g(\boldsymbol{\theta}_t))^T \delta \boldsymbol{\theta} < 0$  时可保证 $g(\boldsymbol{\theta})$ 的值是在下降;
- 当  $\delta \boldsymbol{\theta} = -\nabla g(\boldsymbol{\theta}_t)$  时, 可达到最快的下降速度(略去高阶不计);

# 捆绑调整 Bundle Adjustment

## 最速下降法-算法流程

- 1) 给定初始点 $\theta_0$ ，终止控制函数 $\epsilon > 0$ 和步长 $\lambda$ ，令 $t =$
- 2) 计算 $\nabla g(\theta_t)$ ，若 $\|\nabla g(\theta_t)\| \leq \epsilon$ ，停止迭代，输出 $\theta_t$ ，否则进行下一步；
- 3) 取 $\theta_{t+1} = \theta_t - \lambda \nabla g(\theta_t)$ ,  $t=t+1$  转第2) 步。



越接近极值速度越慢



## 牛顿法—假设函数二阶可微

假设 $g(\theta)$ 在 $\theta_t$ 处二阶可微, 且假定二阶导数 $\nabla^2 g(\theta)$ 总是正定的, 则它在 $\theta_t$ 处, 以 $g(\theta)$ 的二阶近似函数

$$Q(\theta) = g(\theta_t) + (\nabla g(\theta_t))^T \delta\theta + \frac{1}{2} \delta^T \nabla^2 g(\theta_t) \delta\theta, \theta = \theta_t + \delta\theta$$

的极小值点作为下一次迭代点 $\theta_{t+1}$ 。

对上式求梯度并令其等于0, 可以得到


$$\nabla Q(\theta) = \nabla g(\theta_t) + \nabla^2 g(\theta_t) \delta\theta = 0$$

$$\delta\theta = -(\nabla^2 g(\theta_t))^{-1} \nabla g(\theta_t)$$

# 捆绑调整 Bundle Adjustment

## 牛顿法—算法流程

- 1) 给定初始点  $\theta_0$ , 终止控制函数  $\epsilon > 0$  和步长  $\lambda = 1$ , 令  $t = 0$ ;
- 2) 计算  $\nabla g(\theta_t)$ , 若  $\|\nabla g(\theta_t)\| \leq \epsilon$ , 停止迭代, 输出  $\theta_t$ , 否则进行下一步;
- 3) 取  $\theta_{t+1} = \theta_t - (\nabla^2 g(\theta_t))^{-1} \nabla g(\theta_t)$ ,  $t=t+1$  转第2) 步。



— 牛顿法  
— 最速下降法

## 牛顿法

### 1) 速度快

最速下降法是局部平面拟合，牛顿法是局部二次曲面拟合

### 2) 计算量大

需要计算和保存二阶Hessian矩阵的逆矩阵

### 3) 要求初始点离最优点较近

否则无法保证收敛，甚至无法保证下降性

# 捆绑调整 Bundle Adjustment

## Levenberg-Marquardt法-原理与优势

原理:

是一种“信赖域”的方法，当收敛速度较快时，增大信赖域，使算法趋向于牛顿法；当收敛速度较慢时，减小信赖域，使算法趋向于最速梯度法

优势:

- 速度快，只用到一阶矩阵
- 可以在距离初始值较远处得到最优解

# 捆绑调整 Bundle Adjustment

## Levenberg-Marquardt法—实现

$$\nabla^2 g(\boldsymbol{\theta}_t) \delta \boldsymbol{\theta} = -\nabla g(\boldsymbol{\theta}_t),$$

将上述公式中的  $\nabla^2 g(\boldsymbol{\theta}_t)$  替换成  $J^T(\boldsymbol{\theta}_t)J(\boldsymbol{\theta}_t) + \frac{1}{\lambda}I$ , 并且  $\nabla g(\boldsymbol{\theta}_t) = -J^T(\boldsymbol{\theta}_t)(\mathbf{x} - f(\boldsymbol{\theta}_t))$

$$(J^T(\boldsymbol{\theta}_t)J(\boldsymbol{\theta}_t) + \frac{1}{\lambda}I) \delta \boldsymbol{\theta} = J^T(\boldsymbol{\theta}_t)(\mathbf{x} - f(\boldsymbol{\theta}))$$

增量正规方程

,  
 $\lambda$  为信赖域半径,  $J(\boldsymbol{\theta}_t) = \nabla f(\boldsymbol{\theta}_t)$

当  $\lambda$  趋向于无穷大时,  $J^T(\boldsymbol{\theta}_t)J(\boldsymbol{\theta}_t) \delta \boldsymbol{\theta} = -\nabla g(\boldsymbol{\theta}_t)$

当  $\lambda$  趋向于零时,  $\delta \boldsymbol{\theta} = -\nabla g(\boldsymbol{\theta}_t)$

# 捆绑调整 Bundle Adjustment

## Levenberg-Marquardt法—算法流程

1.  $t = 0$  时, 选取初始点  $\theta_0$ , 终止控制常数  $\varepsilon$ , 令  $e^0 = \|\mathbf{x} - f(\theta_0)\|^2$ ,  $\lambda_0 = 10^{-3}$

2. 计算  $J^T(\theta_t)$

3. 构造增量正规方程  $(J^T(\theta)J(\theta) + \lambda_t I)\delta(\theta) = (\theta_{t+1} - \theta_t) = J^T(\theta_t)(\mathbf{x} - f(\theta_t))$

4. 通过求解增量正规方程, 得到  $\delta(\theta)$

如果  $\|\mathbf{x} - f(\theta_t + \delta\theta)\|^2 < e^k$ , 令  $\theta_{t+1} = \theta_t + \delta(\theta)$ ,

如果  $\|\delta(\theta)\| < \varepsilon$ , 终止迭代;

否则, 令  $\lambda_{t+1} = 0.1\lambda_t$ ,  $t = t + 1$ , 执行第2步

否则  $\|\mathbf{x} - f(\theta_t + \delta\theta)\|^2 \geq e^k$ , 令  $\lambda_{t+1} = 10\lambda_t$ , 执行第3步

# 捆绑调整 Bundle Adjustment

---

## Coding-2:

阅读task-3/class3\_test\_lm\_optimization.cc的代码流程，归纳LM算法的流程，并写成伪代码


# 捆绑调整 Bundle Adjustment

## Levenberg-Marquardt法—增量规方程的求解


对称、稀疏

$$\left( J^T(\theta) J(\theta) + \lambda_t I \right) \delta(\theta) = (\theta_{t+1} - \theta_t) = J^T(\theta_t) (\mathbf{x} - f(\theta_t))$$

$$J(\theta_t) = [J_c \ J_x]$$



$$J^T(\theta)$$



$$J^T(\theta) J(\theta)$$



# 捆绑调整 Bundle Adjustment

## Levenberg-Marquardt法-正规方程的求解

$$(J^T(\theta)J(\theta) + \lambda_t I) \delta(\theta) = J^T(\theta_t)(\mathbf{x} - f(\theta_t))$$

左乘

$$\begin{bmatrix} I & -J_{CX}J_{XX}^{-1} \\ 0 & I \end{bmatrix}$$

$$\begin{bmatrix} J_{CC} & J_{CX} \\ J_{CX} & J_{XX} \end{bmatrix} \begin{bmatrix} \delta_C \\ \delta_X \end{bmatrix} = \begin{bmatrix} b_C \\ b_X \end{bmatrix}$$

$$\begin{bmatrix} J_{CC} - J_{CX}J_{XX}^{-1}J_{CX} & 0 \\ J_{CX} & J_{XX} \end{bmatrix} \begin{bmatrix} \delta_C \\ \delta_X \end{bmatrix} = \begin{bmatrix} b_C - J_{CX}J_{XX}^{-1}b_X \\ b_X \end{bmatrix}$$

$$\begin{aligned} (J_{CC} - J_{CX}J_{XX}^{-1}J_{CX})\delta_C &= b_C - J_{CX}J_{XX}^{-1}b_X \\ J_{XX}\delta_X &= b_X - J_{CX}\delta_C \end{aligned}$$

线性方程，共轭梯度法求解

# 捆绑调整 Bundle Adjustment

## 雅阁比矩阵的计算

以第  $i$  个三维点在第  $j$  个相机中的投影为例

$$e_{ij} = \frac{1}{2} \|e_{ij}\|^2 = \frac{1}{2} \|\hat{\mathbf{u}}_{ij} - \mathbf{u}_{ij}(\mathbf{C}_j, \mathbf{X}_i)\|^2 = \frac{1}{2} \left( (u_{ij} - \hat{u}_{ij}(\mathbf{C}_j, \mathbf{X}_i))^2 + (v_{ij} - \hat{v}_{ij}(\mathbf{C}_j, \mathbf{X}_i))^2 \right)$$

$$\xi_{ij} = \begin{bmatrix} \mathbf{C}_j \\ \mathbf{X}_i \end{bmatrix}, \quad \mathbf{C}_j = (f_j, k_1, k_2, \mathbf{R}_j, \mathbf{t}_j)$$

详细过程见参考文件  
BA雅各比矩阵推导.pdf

$$\frac{\partial e_{ij}}{\partial \xi_{ij}^T} = \mathbf{e}_{ij}^T \frac{\partial \mathbf{e}_{ij}}{\partial \xi_{ij}^T} = -\mathbf{e}_{ij}^T \frac{\partial \hat{\mathbf{u}}_{ij}(\mathbf{C}_j, \mathbf{X}_i)}{\partial \xi_{ij}^T}$$

$$\frac{\partial \hat{\mathbf{u}}_{ij}(\mathbf{C}_j, \mathbf{X}_i)}{\partial \xi_{ij}^T} = \begin{bmatrix} \frac{\partial \hat{\mathbf{u}}_{ij}(\mathbf{C}_j, \mathbf{X}_i)}{\partial \mathbf{C}_j^T} & \frac{\partial \hat{\mathbf{u}}_{ij}(\mathbf{C}_j, \mathbf{X}_i)}{\partial \mathbf{X}_i^T} \end{bmatrix} = \begin{bmatrix} \frac{\partial u_{ij}(\mathbf{C}_i, \mathbf{X}_j)}{\partial \mathbf{C}_j^T} & \frac{\partial u_{ij}(\mathbf{C}_i, \mathbf{X}_j)}{\partial \mathbf{X}_j^T} \\ \frac{\partial v_{ij}(\mathbf{C}_i, \mathbf{X}_j)}{\partial \mathbf{C}_j^T} & \frac{\partial v_{ij}(\mathbf{C}_i, \mathbf{X}_j)}{\partial \mathbf{X}_j^T} \end{bmatrix}$$

# 捆绑调整 Bundle Adjustment

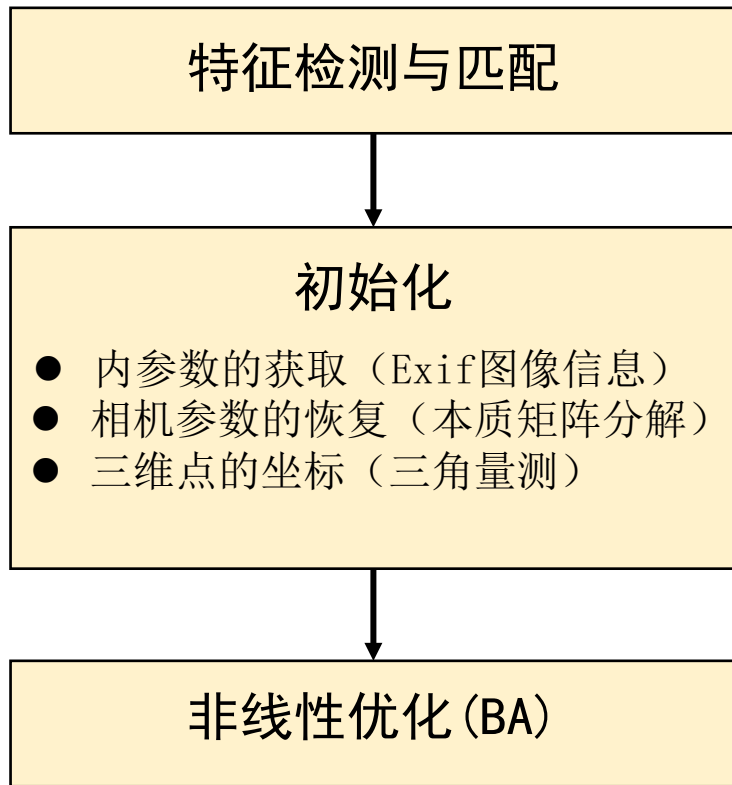
---

## Coding-3:

仔细推导雅阁比矩阵，并完成task3/test\_jacobian.cc中雅阁比矩阵的实现

理解->推导->实现== 真正掌握

# 双视角运动恢复结构





**感谢各位聆听 !**  
Thanks for Listening ●